

Tarea Final (1 Semana)

Curso: Métodos Estadísticos / Machine Learning
Universidad del Desarrollo

Dataset: Online Shoppers Purchasing Intention Dataset (UCI / Kaggle)

Propósito (Metodología TILT)

Al finalizar esta tarea, el estudiante será capaz de:

- Diagnosticar colinealidad mediante matrices de correlación y heatmaps triangulares.
- Seleccionar variables representativas para análisis inferencial y predictivo.
- Ajustar modelos supervisados lineales y probabilísticos (RegLog, LDA, KNN, Naive Bayes).
- Evaluar significancia estadística mediante regresión logística con `statsmodels`.
- Visualizar fronteras de decisión en dos dimensiones usando variables originales.
- Aplicar modelos no supervisados (K-means, GMM, clustering jerárquico, SOM).
- Integrar conclusiones para proponer estrategias accionables de negocio.

Tareas

1. Exploración y Diagnóstico de Datos

Utilice el dataset Online Shoppers Purchasing Intention Dataset.

1.1 Describa brevemente las variables del dataset y en especial la variable objetivo **Revenue**.

1.2 Calcule la matriz de correlación y genere un heatmap triangular:

- Triángulo inferior: colores de correlación.
- Triángulo superior: valores numéricos en formato compacto.

1.3 Identifique bloques de colinealidad e indique una variable representativa por cada bloque (ideal: 6–10 variables). Justifique su selección.

2. Modelos Supervisados

2.1 Regresión Logística (Enfoque Predictivo con sklearn)

Usando las variables seleccionadas:

2.1.1 Construya un pipeline con `StandardScaler`.

2.1.2 Entrene el modelo y evalúe:

- Accuracy
- Precision
- Recall
- F1
- AUC
- Matriz de confusión

2.1.3 Interprete los resultados brevemente.

2.2 Regresión Logística (Enfoque Inferencial con statsmodels)

Usando las mismas variables seleccionadas:

2.2.1 Ajuste un modelo `Logit` con `statsmodels`.

2.2.2 Reporte coeficientes, errores estándar, estadístico z y p-valores.

2.2.3 Comente: *¿Coinciden los resultados inferenciales con los resultados predictivos?*

2.3 Modelos Comparativos

Entrene los siguientes modelos usando las variables seleccionadas:

- LDA
- KNN (con `GridSearchCV` para k y *weights*)
- Naive Bayes Gaussiano (`GaussianNB`)

Para cada modelo:

2.3.1 Entrene usando `train/test`.

2.3.2 Evalúe las métricas anteriores.

2.3.3 Muestre la matriz de confusión.

2.3.4 Discuta cuál modelo detecta mejor la clase positiva (`Revenue = 1`) y por qué.

3. Fronteras de Decisión (2 Variables Originales)

3.1 Seleccione dos variables originales (no transformadas) que sean relevantes.

3.2 Visualice:

- Frontera de decisión de la regresión logística.
- Áreas de clasificación del modelo Naive Bayes (usando GaussianNB).

3.3 Comente diferencias geométricas entre modelos lineales y probabilísticos gaussianos.

4. Modelos No Supervisados

4.1 K-means

4.1.1 Evalúe $k = 2, \dots, 10$.

4.1.2 Seleccione k según el método del codo y el silhouette promedio.

4.1.3 Grafique y describa los clusters encontrados.

4.2 Gaussian Mixture Models

4.2.1 Evalúe 2–8 componentes.

4.2.2 Seleccione el modelo usando BIC y AIC.

4.2.3 Grafique los clusters probabilísticos.

4.3 Clustering Jerárquico

4.3.1 Genere un dendrograma utilizando enlace Ward.

4.3.2 Seleccione una cantidad razonable de clusters y descríbalos.

4.4 Self-Organizing Maps (SOM)

4.4.1 Entrene un SOM utilizando MiniSom.

4.4.2 Muestre:

- U-Matrix
- Mapa de hits
- Distribución de **Revenue** en el mapa

5. Integración Final

- 5.1 Resuma qué variables resultaron más relevantes.
- 5.2 Compare desempeño entre modelos lineales, LDA, KNN y Naive Bayes.
- 5.3 Relacione los clusters con la variable **Revenue**.
- 5.4 Proponga **tres acciones de negocio** basadas en sus hallazgos.

Criterios de Evaluación (20 puntos)

Criterio	Pts
Exploración + análisis de colinealidad	3
Regresión logística (sklearn + statsmodels)	4
Modelos comparativos (LDA, KNN, Naive Bayes)	4
Fronteras de decisión 2D	2
Modelos no supervisados (K-means, GMM, Jerárquico, SOM)	5
Integración final + acciones de negocio	2
Total	20

Entrega: informe en PDF y notebook (.ipynb o .Rmd) con todo el desarrollo.